Projet statistique des Assurances

Ridge Dery Louigarde

2026-03-25

0.Récupération des données

```
##                                   pcs       RUC          cs reves
## 1                            Retraites  7500.000 Moyenne Sup  7500
## 2 Cadres et prof. intellectuelles sup. 25000.000        Aise 60000
## 3 Cadres et prof. intellectuelles sup. 25000.000        Aise 90000
## 4                            Retraites  5500.000 Moyenne Inf  5500
## 5                             Ouvriers  5113.636 Moyenne Inf 11250
## 6                            Retraites  6500.000 Moyenne Inf  6500
##          crevpp region habi                 Ahabi        Atyph agecat
## 1 4eme quartile      1    8 Paris + Agglomeration    Locataire  61-96
## 2 4eme quartile      1    8 Paris + Agglomeration Proprietaire  51-60
## 3 4eme quartile      1    8 Paris + Agglomeration Proprietaire  51-60
## 4 3eme quartile      1    8 Paris + Agglomeration    Locataire  61-96
## 5 2eme quartile      1    8 Paris + Agglomeration    Locataire  41-50
## 6 4eme quartile      1    8 Paris + Agglomeration    Locataire  61-96
##                  Acompm nbpers       enfants            Anat           Bauto
## 1        Personne seule      1 Pas d'enfants Menage francais Pas de vehicule
## 2          Autre menage      3 Pas d'enfants Menage francais Au - 1 vehicule
## 3          Autre menage      3 Pas d'enfants Menage francais Au - 1 vehicule
## 4        Personne seule      1 Pas d'enfants     Non declare Pas de vehicule
## 5 Couple avec enfant(s)      3 Au - 1 enfant Menage francais Au - 1 vehicule
## 6        Personne seule      1 Pas d'enfants Menage francais Pas de vehicule
##   Nbadulte Sinistre1 Sinistre2 Sinistre3 Police1 Police2 Police3 durPolice1
## 1        1       0.6       0.0      0.00    6.31   5.925   0.695  9.0559139
## 2        3       0.0       0.0      2.71    0.00   0.690   0.785  0.0000000
## 3        3       0.0       0.0      2.71    0.00   0.690   0.785  0.0000000
## 4        1       0.0       0.0      3.45    1.32   5.445   0.000  5.6901285
## 5        2       0.4       2.0      0.00    0.40   8.430   1.470  0.6378342
## 6        1       0.0       1.1      0.00    0.00   2.500   2.850  0.0000000
##   Duree NSin censure Sinistre0
## 1   906    2       1  17.58972
## 2    30    3       1  20.92726
## 3    30    4       1  22.02196
## 4   569    2       1  18.01244
## 5    64    5       1  12.11505
## 6    30    2       1  19.60981
```

```
##                                   pcs            RUC
##  Retraites                          :1372   Min.   :  277.8
##  Ouvriers                           :1327   1st Qu.: 3823.5
##  Professions intermediaires         : 887   Median : 5500.0
##  Employes                           : 806   Mean   : 6277.5
```

```
##  Cadres et prof. intellectuelles sup.: 480   3rd Qu.: 7812.5
##  Autres pers. sans activite prof.    : 183   Max.   :35294.1
##  (Other)                             : 297
##           cs           reves                    crevpp        region
##  Aise       : 629   Min.   :   1000   1er quartile :1260   Length:5352
##  Modeste    : 901   1st Qu.:   8500   2eme quartile:1194   Class :character
##  Moyenne Inf:2346   Median :  11250   3eme quartile:1403   Mode  :character
##  Moyenne Sup:1476   Mean   :  14880   4eme quartile:1495
##                     3rd Qu.:  16250
##                     Max.   :3416250
##
##      habi                                          Ahabi               Atyph
##  Length:5352        Communes rurales                :1352   Locataire   :1963
##  Class :character   Paris + Agglomeration           : 697   Non declare :  73
##  Mode  :character   Un. urb. de 10 000 a 99 999 hab.:1031   Proprietaire:3316
##                     Un. urb. de 100 000 hab. et +   :1623
##                     Un. urb. de 2 000 a 9 999 hab.  : 649
##
##
##    agecat                        Acompm         nbpers
##  21-40:1616   Autre menage         :1921   Min.   : 1.000
##  41-50:1483   Couple avec enfant(s):1379   1st Qu.: 2.000
##  51-60: 854   Couple sans enfant   :1293   Median : 3.000
##  61-96:1399   Personne seule       : 759   Mean   : 3.038
##                                            3rd Qu.: 4.000
##                                            Max.   :10.000
##
##           enfants                                  Anat
##  Au - 1 enfant:1379   Au moins une personne etrangere: 115
##  Pas d'enfants:3973   Menage francais                :4866
##                       Non declare                    : 371
##
##
##
##
##              Bauto         Nbadulte       Sinistre1         Sinistre2
##  Au - 1 vehicule:4909   Min.   :1.000   Min.   :  0.000   Min.   : 0.0000
##  Pas de vehicule: 443   1st Qu.:2.000   1st Qu.:  0.000   1st Qu.: 0.0000
##                         Median :2.000   Median :  0.000   Median : 0.0000
##                         Mean   :2.388   Mean   :  1.243   Mean   : 0.1615
##                         3rd Qu.:3.000   3rd Qu.:  0.000   3rd Qu.: 0.0000
##                         Max.   :8.000   Max.   :355.000   Max.   :31.1000
##
##    Sinistre3         Police1           Police2           Police3
##  Min.   : 0.000   Min.   : 0.0000   Min.   :  0.000   Min.   : 0.000
##  1st Qu.: 0.000   1st Qu.: 0.5375   1st Qu.:  3.829   1st Qu.: 0.520
##  Median : 0.705   Median : 1.9500   Median :  9.060   Median : 1.420
##  Mean   : 1.837   Mean   : 3.7507   Mean   : 13.017   Mean   : 2.110
##  3rd Qu.: 2.560   3rd Qu.: 5.0170   3rd Qu.: 17.950   3rd Qu.: 2.833
##  Max.   :40.220   Max.   :54.9850   Max.   :124.109   Max.   :34.743
##
##    durPolice1            Duree             NSin           censure
##  Min.   :0.000e+00   Min.   :   0.0   Min.   : 0.000   Min.   :0.0000
##  1st Qu.:0.000e+00   1st Qu.:  23.0   1st Qu.: 0.000   1st Qu.:0.0000
```

```
##  Median :0.000e+00   Median :  42.5   Median : 4.000   Median :1.0000
##  Mean   :5.191e+08   Mean   : 249.1   Mean   : 4.249   Mean   :0.6179
##  3rd Qu.:2.000e+00   3rd Qu.: 233.0   3rd Qu.: 6.000   3rd Qu.:1.0000
##  Max.   :2.778e+12   Max.   :9877.0   Max.   :30.000   Max.   :1.0000
##
##    Sinistre0
##  Min.   : 0.9652
##  1st Qu.:13.2769
##  Median :17.2558
##  Mean   :16.1732
##  3rd Qu.:19.2718
##  Max.   :27.3074
##
```

```
## [1] 5352
```

```
## [1] 27
```

La base de données comporte 5 352 observations et 27 variables. Avant d'entamer la phase de modélisation, plusieurs étapes de nettoyage et de recodage sont nécessaires afin de garantir la cohérence et l'exploitabilité des données.

Premièrement, certaines variables catégorielles, notamment pcs (catégories socio-professionnelles) et cs (catégories sociales de revenu), ne sont pas correctement codées et doivent être reformatées.

La variable reves (revenu du foyer, estimé par autodéclaration) présente des valeurs incohérentes : bien qu'elle soit censée être comprise dans l'intervalle 0 – 70 000, des valeurs extrêmes (jusqu'à 3 416 250) sont observées. Un traitement des valeurs aberrantes est donc nécessaire.

La variable crevpp (catégorie de revenu par personne), actuellement sous forme de chaîne de caractères, doit être transformée en variable catégorielle ordinale codée de 1 à 4.

La variable RUC (revenu par unité de consommation) doit être recalculée ou ajustée en fonction de la composition du ménage, en tenant compte des unités de consommation définies selon l'âge des individus (par exemple : 1 pour un adulte, 0,8 pour un adolescent, etc.). À partir de cette variable, une nouvelle variable quart (quartiles de revenu par unité de consommation) sera créée.

Plusieurs variables doivent également être recodées : - Atyph (statut d'occupation du logement) : 1 = Propriétaire, 2 = Locataire, 3 = Non déclaré. - agecat (catégorie d'âge du chef de ménage) en 4 classes : 40 = 21–40 ans, 50 = 41–50 ans, 60 = 51–60 ans, 96 = 61–96 ans. - Acompm (composition du ménage) : 1 = Couple avec enfant(s), 2 = Couple sans enfant, 3 = Personne seule, 4 = Autre ménage.

La variable nbpers (nombre de personnes dans le ménage) doit être corrigée : bien que le maximum observé soit 10, elle sera recodée en variable plafonnée (4 et plus = 4).

La variable enfants (présence d'enfants) sera transformée en variable binaire : 0 = Aucun enfant, 1 = Au moins un enfant.

De même, la variable Anat (nationalité du ménage) sera recodée comme suit : 1 = Ménage français, 2 = Présence d'au moins un étranger, 9 = Non déclaré.

Enfin, la variable Bauto (possession d'un véhicule) sera transformée en variable binaire : 0 = Aucun véhicule, 1 = Au moins un véhicule.

L'ensemble de ces traitements vise à harmoniser les formats, corriger les incohérences et produire une base propre, prête pour l'analyse statistique et la modélisation.

1.Nettoyage et recodage des variables

1.1 Correction des valeurs aberrantes (reves)

Verification

```
##
##  1000  2500  3500  4500  5500  6500  7500  8500  9500 11250 13750 16250 18750
##    10    41    98   165   205   241   370   397   427  1001   851   498   414
## 22500 27500 32500 40000 60000
##   347   165    66    34    16
```

```
##  num [1:5352] 7500 60000 NA 5500 11250 ...
```

1.2 Recodage correct de crevpp

Verificatoion

```
##
##    1    2    3    4
## 1260 1194 1403 1495
```

```
##  Factor w/ 4 levels "1","2","3","4": 4 4 4 3 2 4 4 3 4 3 ...
```

1.3 Recodage Atyph

Verification

```
##
##    1    2    3
## 3316 1963   73
```

```
##  Factor w/ 3 levels "1","2","3": 2 1 1 2 2 2 1 2 2 2 ...
```

1.4 Recodage de agecat

Verification

```
##
##   40   50   60   96
## 1616 1483  854 1399
```

```
##  Factor w/ 4 levels "40","50","60",..: 4 3 3 4 2 4 4 1 4 4 ...
```

1.5 Recodage de Acompom

Verification

```
##
##    1    2    3    4
## 1379 1293  759 1921
```

```
##  Factor w/ 4 levels "1","2","3","4": 3 4 4 3 1 3 3 1 3 4 ...
```

1.6 Recodage nbpers

Verification

```
##
##    1    2    3    4
##  759 1479 1021 2093
```

```
##  Factor w/ 4 levels "1","2","3","4": 1 3 3 1 3 1 1 3 1 3 ...
```

1.7 Recodage varible binaire enfants

```
## [1] "factor"
```

```
## [1] "Au - 1 enfant" "Pas d'enfants"
```

Verification

```
##
##    0    1
## 3973 1379
```

```
##  Factor w/ 2 levels "0","1": 1 1 1 1 2 1 1 2 1 1 ...
```

1.8 Recodage de Anat

```
## [1] "factor"
```

Verification

```
##
##    1    2    9
## 4866  115  371
```

```
##  Factor w/ 3 levels "1","2","9": 1 1 1 3 1 1 1 1 1 2 ...
```

1;9 Recodage Bauto

```
## [1] "factor"
```

Verification

```
##
##    0    1
##  443 4909
```

```
##  Factor w/ 2 levels "0","1": 1 2 2 1 2 1 1 2 1 2 ...
```

On met région en facteur et on transforme Bauto et enfants en numerique pour mieux appréhender la modélisation

Verification

```
##
##   1   2   3   4   5   7   8   9
## 816 973 401 558 819 535 707 543
```

```
##  Factor w/ 8 levels "1","2","3","4",..: 1 1 1 1 1 1 1 1 1 1 ...
```

verification complete

```
## 'data.frame':    5352 obs. of  27 variables:
##  $ pcs       : Factor w/ 8 levels "Agr. exploitants",..: 8 4 4 8 6 8 4 6 3 8 ...
##  $ RUC       : num  7500 25000 25000 5500 5114 ...
##  $ cs        : Factor w/ 4 levels "Aise","Modeste",..: 4 1 1 3 3 3 1 4 1 3 ...
##  $ reves     : num  7500 60000 NA 5500 11250 ...
##  $ crevpp    : Factor w/ 4 levels "1","2","3","4": 4 4 4 3 2 4 4 3 4 3 ...
##  $ region    : Factor w/ 8 levels "1","2","3","4",..: 1 1 1 1 1 1 1 1 1 1 ...
##  $ habi      : chr  "8" "8" "8" "8" ...
##  $ Ahabi     : Factor w/ 5 levels "Communes rurales",..: 2 2 2 2 2 2 2 2 2 2 ...
##  $ Atyph     : Factor w/ 3 levels "1","2","3": 2 1 1 2 2 2 1 2 2 2 ...
##  $ agecat    : Factor w/ 4 levels "40","50","60",..: 4 3 3 4 2 4 4 1 4 4 ...
##  $ Acompm    : Factor w/ 4 levels "1","2","3","4": 3 4 4 3 1 3 3 1 3 4 ...
##  $ nbpers    : Factor w/ 4 levels "1","2","3","4": 1 3 3 1 3 1 1 3 1 3 ...
##  $ enfants   : num  0 0 0 0 1 0 0 1 0 0 ...
##  $ Anat      : Factor w/ 3 levels "1","2","9": 1 1 1 3 1 1 1 1 1 2 ...
##  $ Bauto     : num  0 1 1 0 1 0 0 1 0 1 ...
##  $ Nbadulte  : num  1 3 3 1 2 1 1 2 1 3 ...
##  $ Sinistre1 : num  0.6 0 0 0 0.4 0 0.4 0 1.6 0 ...
##  $ Sinistre2 : num  0 0 0 0 2 1.1 0 0 0 0 ...
```

```
##  $ Sinistre3 : num  0 2.71 2.71 3.45 0 0 1.1 0.71 0 0.92 ...
##  $ Police1   : num  6.31 0 0 1.32 0.4 ...
##  $ Police2   : num  5.92 0.69 0.69 5.45 8.43 ...
##  $ Police3   : num  0.695 0.785 0.785 0 1.47 ...
##  $ durPolice1: num  9.056 0 0 5.69 0.638 ...
##  $ Duree     : num  906 30 30 569 64 ...
##  $ NSin      : num  2 3 4 2 5 2 4 4 2 4 ...
##  $ censure   : num  1 1 1 1 1 1 1 1 1 1 ...
##  $ Sinistre0 : num  17.6 20.9 22 18 12.1 ...
```

```
##                                   pcs            RUC
##  Retraites                          :1372   Min.   :  277.8
##  Ouvriers                           :1327   1st Qu.: 3823.5
##  Professions intermediaires         : 887   Median : 5500.0
##  Employes                           : 806   Mean   : 6277.5
##  Cadres et prof. intellectuelles sup.: 480   3rd Qu.: 7812.5
##  Autres pers. sans activite prof.   : 183   Max.   :35294.1
##  (Other)                            : 297
```

```
##           cs           reves       crevpp       region        habi
##  Aise       : 629   Min.   : 1000   1:1260   2      :973   Length:5352
##  Modeste    : 901   1st Qu.: 8500   2:1194   5      :819   Class :character
##  Moyenne Inf:2346   Median :11250   3:1403   1      :816   Mode  :character
##  Moyenne Sup:1476   Mean   :13043   4:1495   8      :707
##                     3rd Qu.:16250            4      :558
##                     Max.   :60000            9      :543
##                     NA's   :6                (Other):936
```

```
##                                Ahabi      Atyph    agecat    Acompm   nbpers
##  Communes rurales                 :1352   1:3316   40:1616   1:1379   1: 759
##  Paris + Agglomeration            : 697   2:1963   50:1483   2:1293   2:1479
##  Un. urb. de 10 000 a 99 999 hab.:1031   3:  73   60: 854   3: 759   3:1021
##  Un. urb. de 100 000 hab. et +    :1623            96:1399   4:1921   4:2093
##  Un. urb. de 2 000 a 9 999 hab.   : 649
```

```
##
```

```
##     enfants       Anat         Bauto           Nbadulte       Sinistre1
##  Min.   :0.0000   1:4866   Min.   :0.0000   Min.   :1.000   Min.   :  0.000
##  1st Qu.:0.0000   2: 115   1st Qu.:1.0000   1st Qu.:2.000   1st Qu.:  0.000
##  Median :0.0000   9: 371   Median :1.0000   Median :2.000   Median :  0.000
##  Mean   :0.2577            Mean   :0.9172   Mean   :2.388   Mean   :  1.243
##  3rd Qu.:1.0000            3rd Qu.:1.0000   3rd Qu.:3.000   3rd Qu.:  0.000
##  Max.   :1.0000            Max.   :1.0000   Max.   :8.000   Max.   :355.000
##
```

```
##    Sinistre2         Sinistre3         Police1           Police2
##  Min.   : 0.0000   Min.   : 0.000   Min.   : 0.0000   Min.   :  0.000
##  1st Qu.: 0.0000   1st Qu.: 0.000   1st Qu.: 0.5375   1st Qu.:  3.829
##  Median : 0.0000   Median : 0.705   Median : 1.9500   Median :  9.060
##  Mean   : 0.1615   Mean   : 1.837   Mean   : 3.7507   Mean   : 13.017
##  3rd Qu.: 0.0000   3rd Qu.: 2.560   3rd Qu.: 5.0170   3rd Qu.: 17.950
##  Max.   :31.1000   Max.   :40.220   Max.   :54.9850   Max.   :124.109
##
```

```
##     Police3         durPolice1            Duree             NSin
##  Min.   : 0.000   Min.   :0.000e+00   Min.   :   0.0   Min.   : 0.000
##  1st Qu.: 0.520   1st Qu.:0.000e+00   1st Qu.:  23.0   1st Qu.: 0.000
##  Median : 1.420   Median :0.000e+00   Median :  42.5   Median : 4.000
```

```
##  Mean   : 2.110   Mean   :5.191e+08   Mean   : 249.1   Mean   : 4.249
##  3rd Qu.: 2.833   3rd Qu.:2.000e+00   3rd Qu.: 233.0   3rd Qu.: 6.000
##  Max.   :34.743   Max.   :2.778e+12   Max.   :9877.0   Max.   :30.000
##
##     censure         Sinistre0
##  Min.   :0.0000   Min.   : 0.9652
##  1st Qu.:0.0000   1st Qu.:13.2769
##  Median :1.0000   Median :17.2558
##  Mean   :0.6179   Mean   :16.1732
##  3rd Qu.:1.0000   3rd Qu.:19.2718
##  Max.   :1.0000   Max.   :27.3074
##
```

2.Modélisation de la de tarification a priori basée sur la variable Sinistre0 (sans aucun 0)

Avant de modélisaer on regarde la distribution des données de Sinistre0

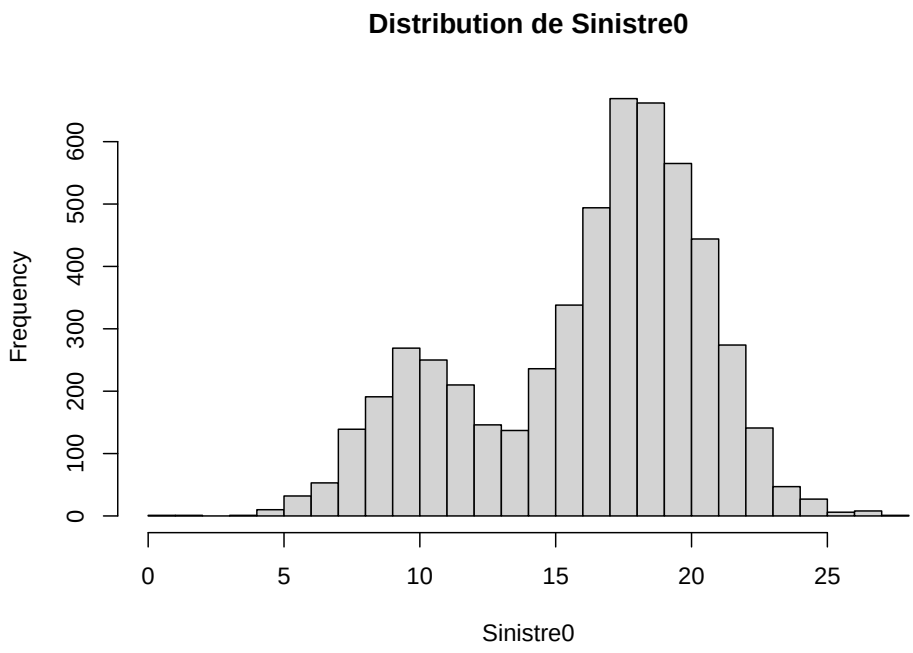

On remarque que la distribution de sinistre0 est asymétrie a droite. On observe une bimodalité suggérant l'existence de sous-populations.

On peut utiliser la modélisation a priori en GLM Gamma avec lien log pour Sinistre0.

2.1 Spécification du modèle GLM Gamma(Modèle a priori)

```
##
## Call:
## glm(formula = Sinistre0 ~ pcs + cs + agecat + RUC + region +
##     Acompm + nbpers + enfants + Anat + Bauto, family = Gamma(link = "log"),
##     data = dat)
##
## Coefficients: (2 not defined because of singularities)
##                                          Estimate Std. Error t value Pr(>|t|)
```

```
## (Intercept)                              2.255e+00  2.509e-02  89.876   <2e-16
## pcsArtisans, comm., chefs d'ent.         5.221e-03  1.764e-02   0.296    0.767
## pcsAutres pers. sans activite prof.      1.684e-04  1.791e-02   0.009    0.992
## pcsCadres et prof. intellectuelles sup.  6.339e-03  1.589e-02   0.399    0.690
## pcsEmployes                             -6.922e-03  1.496e-02  -0.463    0.644
## pcsOuvriers                             -1.654e-02  1.442e-02  -1.147    0.251
## pcsProfessions intermediaires           -1.245e-02  1.494e-02  -0.834    0.405
## pcsRetraites                            -5.760e-03  1.677e-02  -0.344    0.731
## csModeste                               -5.109e-03  1.617e-02  -0.316    0.752
## csMoyenne Inf                            4.547e-03  1.331e-02   0.342    0.733
## csMoyenne Sup                            9.450e-03  1.035e-02   0.913    0.361
## agecat50                                -1.170e-03  6.099e-03  -0.192    0.848
## agecat60                                -8.221e-03  7.348e-03  -1.119    0.263
## agecat96                                -8.773e-03  1.111e-02  -0.790    0.430
## RUC                                      1.110e-05  1.282e-06   8.655   <2e-16
## region2                                 -1.153e-02  7.318e-03  -1.575    0.115
## region3                                 -9.130e-03  9.242e-03  -0.988    0.323
## region4                                 -5.577e-03  8.342e-03  -0.669    0.504
## region5                                 -2.330e-03  7.666e-03  -0.304    0.761
## region7                                  8.675e-03  8.442e-03   1.028    0.304
## region8                                 -8.467e-03  7.761e-03  -1.091    0.275
## region9                                 -6.104e-04  8.359e-03  -0.073    0.942
## Acompm2                                  5.986e-01  1.359e-02  44.063   <2e-16
## Acompm3                                  5.872e-01  9.054e-03  64.849   <2e-16
## Acompm4                                  5.904e-01  6.395e-03  92.328   <2e-16
## nbpers2                                 -8.844e-03  1.196e-02  -0.739    0.460
## nbpers3                                  3.335e-04  5.904e-03   0.056    0.955
## nbpers4                                         NA         NA      NA       NA
## enfants                                         NA         NA      NA       NA
## Anat2                                    1.577e-02  1.395e-02   1.131    0.258
## Anat9                                   -9.780e-03  8.439e-03  -1.159    0.247
## Bauto                                    9.771e-04  8.104e-03   0.121    0.904
##
## (Intercept)                             ***
## pcsArtisans, comm., chefs d'ent.
## pcsAutres pers. sans activite prof.
## pcsCadres et prof. intellectuelles sup.
## pcsEmployes
## pcsOuvriers
## pcsProfessions intermediaires
## pcsRetraites
## csModeste
## csMoyenne Inf
## csMoyenne Sup
## agecat50
## agecat60
## agecat96
## RUC                                     ***
## region2
## region3
## region4
## region5
## region7
## region8
```

```
## region9
## Acompm2                                  ***
## Acompm3                                  ***
## Acompm4                                  ***
## nbpers2
## nbpers3
## nbpers4
## enfants
## Anat2
## Anat9
## Bauto
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 0.0214926)
##
##     Null deviance: 472.12  on 5351  degrees of freedom
## Residual deviance: 122.45  on 5322  degrees of freedom
## AIC: 24374
##
## Number of Fisher Scoring iterations: 4
```

Le modèle a priori indique que le revenu par unité de consommation (RUC) ainsi que la composition du ménage (Acompm2, Acompm3, Acompm4) ont un effet statistiquement significatif sur la prime attendue au seuil de 5%.

En revanche, aucune des modalités des variables socio-démographiques telles que la PCS, la catégorie sociale (cs), l'âge (agecat) ou la région n'apparaît significative à ce seuil, y compris la catégorie d'âge 61 ans (agecat96).

Le coefficient de l'intercept correspond à la valeur de référence du logarithme de la prime attendue pour un individu appartenant à toutes les modalités de référence des variables explicatives.

Par ailleurs, certaines modalités (nbpers4 et enfants) ne sont pas estimées en raison de problèmes de colinéarité (singularités), ce qui indique une redondance d'information avec d'autres variables du modèle.

Ainsi, en dehors du revenu et de la composition du ménage, les autres variables n'ont pas d'effet statistiquement significatif détecté dans ce modèle au seuil de 5%.

2.2 Calcul des facteurs multiplicatifs

On recupère que les coefficients significatifs

```
##  agecat96   Acompm2   Acompm3   Acompm4       RUC
## 0.9912656 1.8196102 1.7988904 1.8047636 1.0000111
```

Prime 1% plus faible pour les chefs de ménage 61 ans par rapport à la catégorie de référence (21–40 ans). Prime 82% plus élevée pour les couples sans enfant par rapport à la référence (couple avec enfant). Prime 79% plus élevée pour une personne seule. Prime 80% plus élevée pour les autres types de ménage.

2.3 Spécification du modèle GLM Gamma a posteriori

```
##
## Call:
## glm(formula = Sinistre0 ~ pcs + cs + agecat + RUC + region +
##     Acompm + nbpers + enfants + Anat + Bauto + Police1 + Police2 +
##     Police3, family = Gamma(link = "log"), data = dat)
##
## Coefficients: (2 not defined because of singularities)
```

```
##                                          Estimate Std. Error t value Pr(>|t|)
## (Intercept)                              2.250e+00  2.535e-02  88.745   <2e-16
## pcsArtisans, comm., chefs d'ent.         5.616e-03  1.764e-02   0.318   0.7502
## pcsAutres pers. sans activite prof.     -9.084e-04  1.792e-02  -0.051   0.9596
## pcsCadres et prof. intellectuelles sup.  6.000e-03  1.589e-02   0.378   0.7058
## pcsEmployes                             -7.482e-03  1.496e-02  -0.500   0.6171
## pcsOuvriers                             -1.734e-02  1.444e-02  -1.201   0.2299
## pcsProfessions intermediaires           -1.304e-02  1.494e-02  -0.873   0.3827
## pcsRetraites                            -6.593e-03  1.678e-02  -0.393   0.6943
## csModeste                               -5.316e-03  1.617e-02  -0.329   0.7424
## csMoyenne Inf                            4.371e-03  1.331e-02   0.328   0.7426
## csMoyenne Sup                            9.406e-03  1.035e-02   0.909   0.3634
## agecat50                                -1.699e-03  6.104e-03  -0.278   0.7808
## agecat60                                -8.473e-03  7.357e-03  -1.152   0.2495
## agecat96                                -9.525e-03  1.112e-02  -0.857   0.3917
## RUC                                      1.107e-05  1.282e-06   8.636   <2e-16
## region2                                 -1.239e-02  7.334e-03  -1.689   0.0912
## region3                                 -8.919e-03  9.370e-03  -0.952   0.3412
## region4                                 -5.766e-03  8.386e-03  -0.688   0.4918
## region5                                 -2.583e-03  7.669e-03  -0.337   0.7362
## region7                                  8.259e-03  8.454e-03   0.977   0.3287
## region8                                 -8.984e-03  7.778e-03  -1.155   0.2481
## region9                                 -1.708e-03  8.377e-03  -0.204   0.8385
## Acompm2                                  5.991e-01  1.360e-02  44.043   <2e-16
## Acompm3                                  5.918e-01  9.586e-03  61.730   <2e-16
## Acompm4                                  5.906e-01  6.409e-03  92.154   <2e-16
## nbpers2                                 -6.008e-03  1.213e-02  -0.495   0.6205
## nbpers3                                  2.650e-03  6.132e-03   0.432   0.6656
## nbpers4                                         NA         NA      NA       NA
## enfants                                         NA         NA      NA       NA
## Anat2                                    1.607e-02  1.395e-02   1.152   0.2492
## Anat9                                   -9.421e-03  8.441e-03  -1.116   0.2644
## Bauto                                    6.072e-04  8.106e-03   0.075   0.9403
## Police1                                  6.989e-04  4.129e-04   1.692   0.0906
## Police2                                  1.218e-04  1.808e-04   0.674   0.5004
## Police3                                  5.807e-04  8.934e-04   0.650   0.5157
##
## (Intercept)                             ***
## pcsArtisans, comm., chefs d'ent.
## pcsAutres pers. sans activite prof.
## pcsCadres et prof. intellectuelles sup.
## pcsEmployes
## pcsOuvriers
## pcsProfessions intermediaires
## pcsRetraites
## csModeste
## csMoyenne Inf
## csMoyenne Sup
## agecat50
## agecat60
## agecat96
## RUC                                     ***
## region2                                 .
## region3
```

```
## region4
## region5
## region7
## region8
## region9
## Acompm2                                  ***
## Acompm3                                  ***
## Acompm4                                  ***
## nbpers2
## nbpers3
## nbpers4
## enfants
## Anat2
## Anat9
## Bauto
## Police1                                  .
## Police2
## Police3
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 0.02148765)
##
##     Null deviance: 472.12  on 5351  degrees of freedom
## Residual deviance: 122.36  on 5319  degrees of freedom
## AIC: 24376
##
## Number of Fisher Scoring iterations: 4
```

La composition du ménage et le revenu par unité de consommation (RUC) sont les principaux déterminants de la prime même après ajout des polices. L'effet direct des polices sur Sinistre0 est faible et non significatif, probablement à cause de l'endogénéité ou de la corrélation avec d'autres variables. D'un point de vue économique, il est raisonnable de supposer une endogénéité des polices, car les ménages les plus exposés au risque sont susceptibles de souscrire davantage de couvertures. Par conséquent, les coefficients associés aux variables de police doivent être interprétés avec prudence. Certaines variables (enfants, nbpers4) ne peuvent pas être estimées à cause de colinéarité.

2.4 Hétéroscédasticité

```
##
## z test of coefficients:
##
##                                          Estimate  Std. Error z value
## (Intercept)                             2.2497e+00  2.4253e-02 92.7625
## pcsArtisans, comm., chefs d'ent.        5.6160e-03  1.7921e-02  0.3134
## pcsAutres pers. sans activite prof.    -9.0843e-04  1.7621e-02 -0.0516
## pcsCadres et prof. intellectuelles sup.  5.9999e-03  1.6687e-02  0.3596
## pcsEmployes                            -7.4825e-03  1.6058e-02 -0.4660
## pcsOuvriers                            -1.7336e-02  1.5524e-02 -1.1167
## pcsProfessions intermediaires          -1.3045e-02  1.5804e-02 -0.8254
## pcsRetraites                           -6.5930e-03  1.6369e-02 -0.4028
## csModeste                              -5.3157e-03  1.4061e-02 -0.3780
## csMoyenne Inf                           4.3709e-03  1.1287e-02  0.3873
## csMoyenne Sup                           9.4057e-03  8.9652e-03  1.0491
## agecat50                               -1.6988e-03  6.5396e-03 -0.2598
```

```
## agecat60                                -8.4727e-03  6.9516e-03 -1.2188
## agecat96                                -9.5248e-03  9.5451e-03 -0.9979
## RUC                                      1.1073e-05  1.0405e-06 10.6423
## region2                                 -1.2388e-02  7.5834e-03 -1.6336
## region3                                 -8.9185e-03  9.3245e-03 -0.9565
## region4                                 -5.7657e-03  8.4524e-03 -0.6821
## region5                                 -2.5834e-03  7.6468e-03 -0.3378
## region7                                  8.2589e-03  8.2509e-03  1.0010
## region8                                 -8.9840e-03  7.8340e-03 -1.1468
## region9                                 -1.7075e-03  8.1359e-03 -0.2099
## Acompm2                                  5.9906e-01  1.1935e-02 50.1955
## Acompm3                                  5.9177e-01  9.5333e-03 62.0745
## Acompm4                                  5.9062e-01  7.1853e-03 82.1987
## nbpers2                                 -6.0080e-03  1.0125e-02 -0.5934
## nbpers3                                  2.6502e-03  6.6761e-03  0.3970
## Anat2                                    1.6072e-02  1.6228e-02  0.9904
## Anat9                                   -9.4215e-03  7.8489e-03 -1.2004
## Bauto                                    6.0720e-04  7.0554e-03  0.0861
## Police1                                  6.9887e-04  4.2246e-04  1.6543
## Police2                                  1.2182e-04  1.9030e-04  0.6401
## Police3                                  5.8070e-04  9.3530e-04  0.6209
##                                         Pr(>|z|)
## (Intercept)                              < 2e-16 ***
## pcsArtisans, comm., chefs d'ent.         0.75399
## pcsAutres pers. sans activite prof.      0.95888
## pcsCadres et prof. intellectuelles sup.  0.71918
## pcsEmployes                              0.64124
## pcsOuvriers                              0.26410
## pcsProfessions intermediaires            0.40914
## pcsRetraites                             0.68712
## csModeste                                0.70540
## csMoyenne Inf                            0.69857
## csMoyenne Sup                            0.29411
## agecat50                                 0.79504
## agecat60                                 0.22291
## agecat96                                 0.31834
## RUC                                      < 2e-16 ***
## region2                                  0.10235
## region3                                  0.33884
## region4                                  0.49515
## region5                                  0.73549
## region7                                  0.31684
## region8                                  0.25147
## region9                                  0.83376
## Acompm2                                  < 2e-16 ***
## Acompm3                                  < 2e-16 ***
## Acompm4                                  < 2e-16 ***
## nbpers2                                  0.55292
## nbpers3                                  0.69140
## Anat2                                    0.32197
## Anat9                                    0.23000
## Bauto                                    0.93142
## Police1                                  0.09807 .
## Police2                                  0.52209
```

```
## Police3                                   0.53468
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Afin de corriger une éventuelle hétéroscédasticité, des erreurs standards robustes ont été utilisées. Les résultats obtenus confirment la robustesse des principaux déterminants identifiés précédemment. En particulier, le revenu par unité de consommation (RUC) ainsi que la composition du ménage restent hautement significatifs. L'effet des variables de police demeure faible et peu significatif, ce qui peut s'expliquer par un problème d'endogénéité.

3.Calibrage et comparaison des modèles tobit, tobit généralisé ou double hurdle (librairie mhurdle)

Avant de choisir entre sinistre1, sinistre2 ou sinistre 3. Analysons la configuration de ces derniers.

```
##    Variable Nb_zeros Pourcentage
## 1 Sinistre1     4085   0.7632661
## 2 Sinistre2     4797   0.8963004
## 3 Sinistre3     1780   0.3325859
```

Nous avons choisi la variable Sinistre1 pour la modélisation, car elle présente une proportion significative d'observations positives (24%) tout en conservant un nombre raisonnable d'observations nulles.

Sinistre2 ne comporte que 555 observations positives sur 5352, ce qui est trop faible pour calibrer un modèle Tobit ou hurdle de manière stable. Sinistre3, bien que présentant moins de zéros, a une distribution différente et un nombre limité d'observations positives pour estimer les effets des variables explicatives.

Ainsi, Sinistre1 offre un compromis optimal entre suffisamment de données positives pour estimer les montants et un nombre suffisant de zéros pour modéliser correctement la partie "probabilité de sinistre".

3.1 Tobit sur Sinistre1

```
##
## Call:
## tobit(formula = Sinistre1 ~ pcs + agecat + RUC, left = 0, data = dat)
##
## Observations:
##          Total  Left-censored     Uncensored Right-censored
##           5352           4085           1267              0
##
## Coefficients:
##                                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)                             -2.113e+01  3.045e+00  -6.939 3.96e-12
## pcsArtisans, comm., chefs d'ent.         3.271e+00  3.671e+00   0.891  0.37287
## pcsAutres pers. sans activite prof.      9.429e+00  3.575e+00   2.638  0.00835
## pcsCadres et prof. intellectuelles sup.  9.050e+00  3.275e+00   2.763  0.00573
## pcsEmployes                              7.381e+00  3.102e+00   2.380  0.01733
## pcsOuvriers                              6.106e+00  3.038e+00   2.010  0.04446
## pcsProfessions intermediaires            9.096e+00  3.100e+00   2.934  0.00334
## pcsRetraites                             5.024e+00  3.489e+00   1.440  0.14985
## agecat50                                -1.245e+00  9.911e-01  -1.256  0.20907
## agecat60                                -2.704e+00  1.239e+00  -2.182  0.02909
## agecat96                                -6.208e+00  2.133e+00  -2.910  0.00362
## RUC                                     -2.457e-04  1.207e-04  -2.035  0.04184
## Log(scale)                               3.045e+00  2.112e-02 144.200  < 2e-16
##
## (Intercept)                             ***
```

```
## pcsArtisans, comm., chefs d'ent.
## pcsAutres pers. sans activite prof.     **
## pcsCadres et prof. intellectuelles sup. **
## pcsEmployes                             *
## pcsOuvriers                             *
## pcsProfessions intermediaires           **
## pcsRetraites
## agecat50
## agecat60                                *
## agecat96                                **
## RUC                                     *
## Log(scale)                              ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Scale: 21.01
##
## Gaussian distribution
## Number of Newton-Raphson Iterations: 4
## Log-likelihood: -7110 on 13 Df
## Wald-statistic: 85.83 on 11 Df, p-value: 1.0912e-13
```

```
## [1] 14246.49
```

Avec p-value 1e-13, le modèle Tobit est globalement significatif. La catégorie socio-professionnelle (PCS) influence fortement le sinistre. Contrairement au modèle GLM sur Sinistre0, certaines modalités de PCS deviennent significatives :

Autres sans activité professionnelle (p 0.6%) Cadres et professions intellectuelles supérieures (p 0.6%) Employés (p 1.3%) Ouvriers (p 3.5%) Professions intermédiaires (p 0.2%)

RUC Estimate = -2.457e-04 ce qui traduit que les ménages plus aisés ont moins de sinistres (ou mieux assurés / plus prudents) On trouve un AIC = 14246.49

Toutefois, ce modèle repose sur l'hypothèse restrictive qu'un mécanisme unique régit à la fois la probabilité d'occurrence du sinistre et le montant en cas de sinistre, ce qui peut apparaître peu réaliste en contexte assurantiel. Cette remarque est particulièrement pertinente ici, car près de 76% des observations sont égales à zéro, ce qui suggère que le processus de survenue du sinistre et le processus du montant pourraient être différents.

3.2 Tobit généralisé

```
## --------------------------------------------
## Tobit 2 model (sample selection model)
## Maximum Likelihood estimation
## Newton-Raphson maximisation, 4 iterations
## Return code 8: successive function values within relative tolerance limit (reltol)
## Log-Likelihood: -8328.351
## 5352 observations (4085 censored and 1267 observed)
## 27 free parameters (df = 5325)
## Probit selection equation:
##                                        Estimate Std. Error t value Pr(>|t|)
## (Intercept)                            -0.88205    0.14246  -6.191 6.41e-10
## pcsArtisans, comm., chefs d'ent.        0.19226    0.17434   1.103 0.270153
## pcsAutres pers. sans activite prof.     0.49361    0.17203   2.869 0.004129
## pcsCadres et prof. intellectuelles sup. 0.35806    0.15217   2.353 0.018654
## pcsEmployes                             0.36736    0.14712   2.497 0.012554
```

```
## pcsOuvriers                              0.24983    0.14457   1.728 0.084037
## pcsProfessions intermediaires            0.41011    0.14628   2.804 0.005072
## pcsRetraites                             0.22527    0.16601   1.357 0.174840
## agecat50                                -0.08118    0.04867  -1.668 0.095397
## agecat60                                -0.18167    0.06035  -3.010 0.002623
## agecat96                                -0.36643    0.10208  -3.590 0.000334
##
## (Intercept)                             ***
## pcsArtisans, comm., chefs d'ent.
## pcsAutres pers. sans activite prof.     **
## pcsCadres et prof. intellectuelles sup. *
## pcsEmployes                             *
## pcsOuvriers                             .
## pcsProfessions intermediaires           **
## pcsRetraites
## agecat50                                .
## agecat60                                **
## agecat96                                ***
## Outcome equation:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)    2.58229    3.17266   0.814   0.4157
## csModeste     -0.05328    2.19609  -0.024   0.9806
## csMoyenne Inf -1.75521    1.92823  -0.910   0.3627
## csMoyenne Sup  1.82537    1.89380   0.964   0.3352
## region2        2.57889    1.82908   1.410   0.1586
## region3        5.57539    2.22355   2.507   0.0122 *
## region4        3.50252    2.09621   1.671   0.0948 .
## region5        4.03207    1.94520   2.073   0.0382 *
## region7        3.16246    2.15991   1.464   0.1432
## region8        1.82414    1.87116   0.975   0.3297
## region9        1.39280    1.94178   0.717   0.4732
## nbpers2        0.43066    1.81385   0.237   0.8123
## nbpers3       -0.16131    1.94390  -0.083   0.9339
## nbpers4        3.88619    1.76396   2.203   0.0276 *
##    Error terms:
##       Estimate Std. Error t value Pr(>|t|)
## sigma 17.88709    0.36495  49.013   <2e-16 ***
## rho   -0.05867    0.10160  -0.577    0.564
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## --------------------------------------------

## 'log Lik.' 16710.7 (df=27)
```

Pour l'equjation de sélection

Le profil socio-professionnel influence la probabilité de sinistre. L'âge réduit la probabilité de sinistre. Les ménages plus âgés sont moins exposés au risque.

Pour l'équation du montant

Le modèle explique mal le montant du sinistre

Conclusion

Le paramètre de corrélation rho= -0.06 est non significatif (p-value = 0.564), ce qui indique l'absence de corrélation entre les équations de sélection et de montant. Il n'y a donc pas de biais de sélection détecté.

Par ailleurs, la comparaison des modèles via le critère d'information d'Akaike montre que le modèle Tobit généralisé (AIC 16710) est moins performant que le Tobit simple (AIC 14246).

Ainsi, le modèle Tobit généralisé n'apporte pas d'amélioration et un modèle plus parcimonieux comme le Tobit standard est préférable.

On peut néanmoins envisager des alternatives comme le modèle double hurdle, qui permet de modéliser séparément la décision de participation et le montant.

3.3 Modèle hurdle sur Sinistre1

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   0.065   0.400   0.900   5.249   3.000 355.000
```

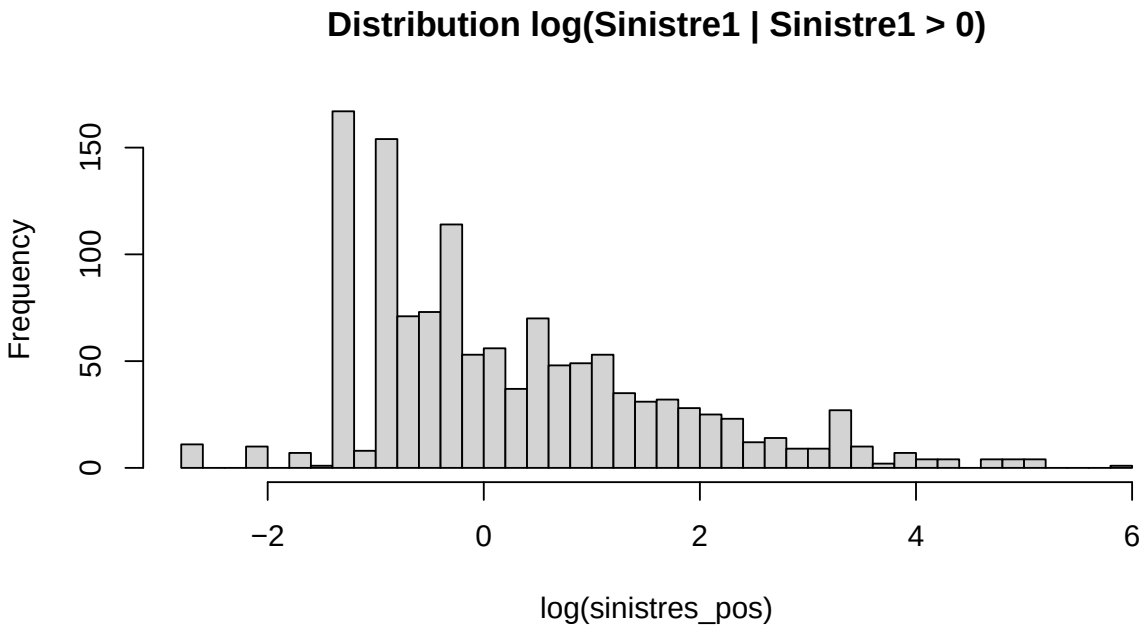

L'analyse de la distribution des montants positifs de sinistre montre que la transformation logarithmique ne permet pas d'obtenir une distribution symétrique. L'hypothèse log-normale apparaît donc inadaptée. En revanche, la forte asymétrie à droite plaide en faveur d'une modélisation par une loi Gamma, plus conforme aux propriétés empiriques des données. Comme mhurdle ne supporte pas dist = "gamma" nativement on va estimer le Hurdle en deux parties séparées.

```
##
## Call:
## glm(formula = I(Sinistre1 > 0) ~ pcs + agecat, family = binomial(link = "logit"),
##     data = dat)
##
## Coefficients:
##                                      Estimate Std. Error z value Pr(>|z|)
## (Intercept)                          -1.47004    0.25636  -5.734 9.79e-09
## pcsArtisans, comm., chefs d'ent.      0.35299    0.30983   1.139 0.254581
## pcsAutres pers. sans activite prof.   0.86172    0.30303   2.844 0.004459
## pcsCadres et prof. intellectuelles sup.  0.62025    0.27180   2.282 0.022487
## pcsEmployes                           0.64026    0.26367   2.428 0.015172
## pcsOuvriers                           0.44048    0.25975   1.696 0.089927
```

```
## pcsProfessions intermediaires           0.70863    0.26208   2.704 0.006854
## pcsRetraites                            0.39497    0.29885   1.322 0.186292
## agecat50                               -0.13399    0.08162  -1.642 0.100673
## agecat60                               -0.30789    0.10259  -3.001 0.002689
## agecat96                               -0.63487    0.17773  -3.572 0.000354
##
## (Intercept)                            ***
## pcsArtisans, comm., chefs d'ent.
## pcsAutres pers. sans activite prof.    **
## pcsCadres et prof. intellectuelles sup. *
## pcsEmployes                            *
## pcsOuvriers                            .
## pcsProfessions intermediaires          **
## pcsRetraites
## agecat50
## agecat60                               **
## agecat96                               ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 5858.1  on 5351  degrees of freedom
## Residual deviance: 5756.2  on 5341  degrees of freedom
## AIC: 5778.2
##
## Number of Fisher Scoring iterations: 4
```

```
##
## Call:
## glm(formula = Sinistre1 ~ nbpers + cs + region, family = Gamma(link = "log"),
##     data = dat[dat$Sinistre1 > 0, ])
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.80349    0.35020   2.294  0.02193 *
## nbpers2       -0.02154    0.30179  -0.071  0.94312
## nbpers3       -0.17991    0.32371  -0.556  0.57846
## nbpers4        0.58448    0.29321   1.993  0.04644 *
## csModeste      0.19687    0.36576   0.538  0.59051
## csMoyenne Inf -0.23582    0.32102  -0.735  0.46273
## csMoyenne Sup  0.32341    0.31532   1.026  0.30525
## region2        0.42315    0.30445   1.390  0.16482
## region3        0.96840    0.37041   2.614  0.00904 **
## region4        0.71550    0.34900   2.050  0.04056 *
## region5        0.79841    0.32393   2.465  0.01384 *
## region7        0.61730    0.35968   1.716  0.08637 .
## region8        0.53323    0.31161   1.711  0.08729 .
## region9        0.33472    0.32309   1.036  0.30041
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Gamma family taken to be 8.855754)
##
```

```
##     Null deviance: 3554  on 1266  degrees of freedom
## Residual deviance: 3268  on 1253  degrees of freedom
## AIC: 5958
##
## Number of Fisher Scoring iterations: 11
```

```
## [1] 11736.18
```

L'AIC du modèle hurdle est de 11736.18, il a été obtenu en sommant les AIC des deux équations AIC , conformément à l'hypothèse d'indépendance entre les processus de fréquence et de gravité. La comparaison avec le modèle Tobit montre que le modèle hurdle offre un meilleur compromis entre qualité d'ajustement et complexité.

La comparaison des modèles met en évidence les limites du modèle Tobit, qui repose sur une hypothèse restrictive d'un mécanisme unique avec un AIC=14246.49 . Le modèle Tobit généralisé, bien que plus flexible, ne révèle pas de corrélation significative entre les processus de sélection et de montant possedant un AIC = 16710.7 plus élévé que celui du Tobit simple. En revanche, le modèle hurdle apparaît comme le plus adapté, en permettant une modélisation distincte de la fréquence et de la gravité des sinistres, conformément à la théorie actuarielle. De plus, il présente une meilleure qualité d'ajustement au regard du critère d'AIC.

Les diagnostics du modèle hurdle (voir Annexe A) révèlent un ajustement globalement satisfaisant, bien que perfectible. Pour la partie logistique, le graphique des résidus vs valeurs ajustées présente la structure en deux bandes attendue pour un modèle binaire, tandis que le QQ-plot met en évidence des queues plus lourdes que la normale, traduisant un pouvoir discriminant modéré du modèle — un indicateur de performance complémentaire tel que l'AUC permettrait de le quantifier précisément. Pour la partie Gamma, la ligne de lissage reste globalement plate, ce qui confirme l'absence de biais systématique ; cependant, plusieurs résidus de déviance supérieurs à 4 signalent la présence d'observations influentes correspondant vraisemblablement à des sinistres de grande ampleur. Par ailleurs, le saut observé en queue droite du QQ-plot logit confirme que ces cas extrêmes ne sont pas pleinement capturés par la distribution supposée, et qu'une modélisation de la queue par une loi de Pareto généralisée constituerait une piste d'amélioration naturelle. Ces limites, inhérentes aux données de sinistres, ne remettent pas en cause la pertinence du modèle hurdle retenu.

4.Modélisation du nombre de sinistres nsin des ménages avec les variables disponibles (hors polices, et variable de durée)

Analyse des données de nsin avant modélisation

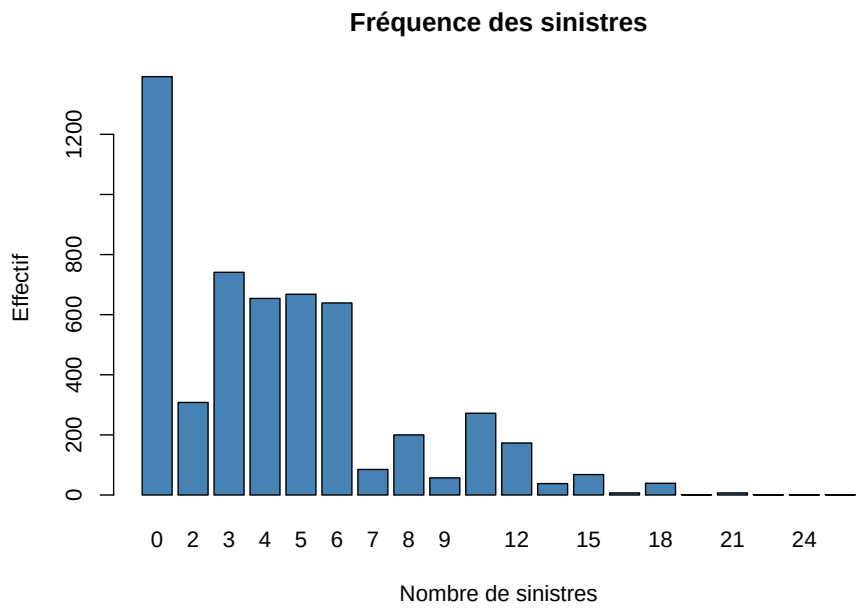


```
## [1] 4.249253
```

```
## [1] 14.5299
```

```
## [1] 0.2600897
```

La distribution du nombre de sinistres est fortement asymétrique, avec une concentration importante en zéro (environ 26 % des observations). Par ailleurs, la variance (14,53) est nettement supérieure à la moyenne (4,25), ce qui met en évidence une surdispersion.

Ces éléments suggèrent que le modèle de Poisson, qui impose l'égalité entre moyenne et variance, est inadapté dans ce contexte. En revanche, un modèle plus flexible, tel que la binomiale négative, apparaît plus approprié pour capturer l'hétérogénéité des comportements de sinistralité.

Enfin, bien que la proportion de zéros soit significative, elle reste modérée, ce qui ne justifie pas nécessairement le recours à un modèle à inflation de zéros dans un premier temps.

4.1 Calibration et comparaison des deux modèles (poisson & binomiale négative)

```
##
## Attachement du package : 'MASS'
```

```
## L'objet suivant est masqué depuis 'package:dplyr':
##
##     select
```

```
##             df      AIC
## modele_pois 30 29126.55
## modele_nb   31 25948.74
```

Le modèle Binomiale négative est clairement préféré pour expliquer le nombre de sinistres, car il s'ajuste mieux à la variance observée et prend en compte la surdispersion structurelle des données de sinistres.

```
##
## Call:
## glm.nb(formula = dat$NSin ~ pcs + cs + agecat + RUC + region +
##     Acompm + nbpers + enfants + Anat + Bauto, data = dat, init.theta = 2.046512489,
##     link = log)
```

```
##
## Coefficients: (2 not defined because of singularities)
##                                          Estimate Std. Error z value Pr(>|z|)
## (Intercept)                              1.619e+00  1.559e-01  10.384  < 2e-16
## pcsArtisans, comm., chefs d'ent.         1.471e-01  1.032e-01   1.425 0.154023
## pcsAutres pers. sans activite prof.      3.381e-01  1.069e-01   3.163 0.001562
## pcsCadres et prof. intellectuelles sup.  3.118e-01  9.321e-02   3.345 0.000822
## pcsEmployes                              2.890e-01  8.778e-02   3.293 0.000992
## pcsOuvriers                              2.192e-01  8.454e-02   2.593 0.009515
## pcsProfessions intermediaires            3.133e-01  8.760e-02   3.577 0.000348
## pcsRetraites                             1.452e-01  1.012e-01   1.435 0.151245
## csModeste                               -5.988e-02  1.027e-01  -0.583 0.559842
## csMoyenne Inf                            6.029e-03  8.508e-02   0.071 0.943507
## csMoyenne Sup                           -3.298e-02  6.611e-02  -0.499 0.617903
## agecat50                                -9.621e-02  3.540e-02  -2.718 0.006576
## agecat60                                -1.145e-01  4.383e-02  -2.613 0.008981
## agecat96                                -1.857e-01  6.925e-02  -2.681 0.007337
## RUC                                     -4.723e-06  8.258e-06  -0.572 0.567357
## region2                                 -3.478e-02  4.402e-02  -0.790 0.429358
## region3                                 -7.824e-02  5.517e-02  -1.418 0.156169
## region4                                  4.662e-02  4.947e-02   0.942 0.346001
## region5                                 -1.235e-01  4.630e-02  -2.668 0.007626
## region7                                 -8.864e-02  5.112e-02  -1.734 0.082959
## region8                                  6.197e-02  4.618e-02   1.342 0.179617
## region9                                  1.706e-01  4.963e-02   3.436 0.000589
## Acompm2                                 -4.036e-02  8.178e-02  -0.493 0.621667
## Acompm3                                 -1.343e+00  5.854e-02 -22.946  < 2e-16
## Acompm4                                  5.605e-02  3.643e-02   1.539 0.123872
## nbpers2                                 -6.364e-01  7.181e-02  -8.862  < 2e-16
## nbpers3                                 -4.054e-01  3.399e-02 -11.929  < 2e-16
## nbpers4                                         NA         NA      NA       NA
## enfants                                         NA         NA      NA       NA
## Anat2                                   -3.743e-03  8.074e-02  -0.046 0.963022
## Anat9                                   -3.756e-02  5.427e-02  -0.692 0.488891
## Bauto                                    5.959e-02  5.258e-02   1.133 0.257085
##
## (Intercept)                             ***
## pcsArtisans, comm., chefs d'ent.
## pcsAutres pers. sans activite prof.     **
## pcsCadres et prof. intellectuelles sup. ***
## pcsEmployes                             ***
## pcsOuvriers                             **
## pcsProfessions intermediaires           ***
## pcsRetraites
## csModeste
## csMoyenne Inf
## csMoyenne Sup
## agecat50                                **
## agecat60                                **
## agecat96                                **
## RUC
## region2
## region3
## region4
```

```
## region5                                  **
## region7                                  .
## region8
## region9                                  ***
## Acompm2
## Acompm3                                  ***
## Acompm4
## nbpers2                                  ***
## nbpers3                                  ***
## nbpers4
## enfants
## Anat2
## Anat9
## Bauto
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(2.0465) family taken to be 1)
##
##     Null deviance: 8618.8  on 5351  degrees of freedom
## Residual deviance: 6871.0  on 5322  degrees of freedom
## AIC: 25949
##
## Number of Fisher Scoring iterations: 1
##
##
##               Theta:  2.0465
##           Std. Err.:  0.0753
##
##  2 x log-likelihood:  -25886.7370
```

Variables significatives : certaines catégories socio-professionnelles (pcs), groupes d'âge (agecat), nombre de personnes par ménage (nbpers), et certaines régions (region5, region9). Le modèle binomiale négative confirme que profil socio-démographique, âge, taille du ménage et type de couverture influencent la fréquence des sinistres. Les coefficients positifs augmentent le nombre attendu de sinistres, tandis que les coefficients négatifs le diminuent. La surdispersion est correctement capturée par ce modèle, contrairement au modèle Poisson. parexemple : . Les ménages plus âgés ont tendance à avoir moins de sinistres. L'effet s'accentue avec l'âge, ce qui pourrait refléter une conduite plus prudente ou moins de déplacements.

. Étonnamment, un ménage avec 2 ou 3 personnes semble avoir moins de sinistres que la catégorie de référence (1 personne), ce qui pourrait s'expliquer par des comportements partagés ou une assurance combinée qui limite le risque par personne.

. Certaines régions montrent un effet significatif sur le nombre de sinistres, reflétant des facteurs locaux de risque

5.On modélise la durée de soucription d'un contrat tout en prenant en consideration la variable "censure" qui indique les données censurées sur la durée.

5.1 Estimateur de Kaplan-Meier

```
## Ignoring unknown labels:
## * fill : "Strata"
## Ignoring unknown labels:
## * fill : "Strata"
```

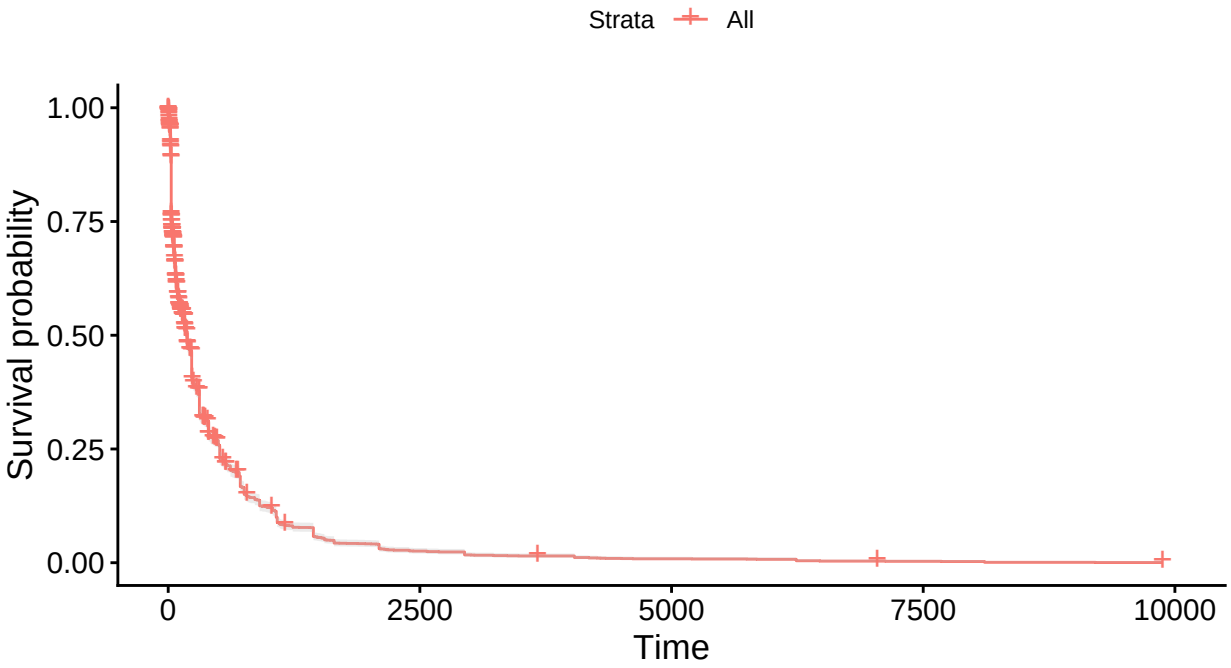

La courbe de Kaplan-Meier est décroissante et convexe, traduisant une diminution progressive de la probabilité de maintien du contrat au cours du temps. La forme convexe indique un taux de résiliation plus élevé en début de relation contractuelle, qui tend à diminuer avec l'ancienneté. Ce phénomène reflète un effet de sélection, les assurés les moins fidèles quittant rapidement le portefeuille, tandis que les assurés restants présentent une fidélité accrue.

5.2 Comparaison de plusieurs KP selon le type d'habitat ou le fait de posséder une voiture ou selon l'age.

a) Selon le type d'habitat (Anat)

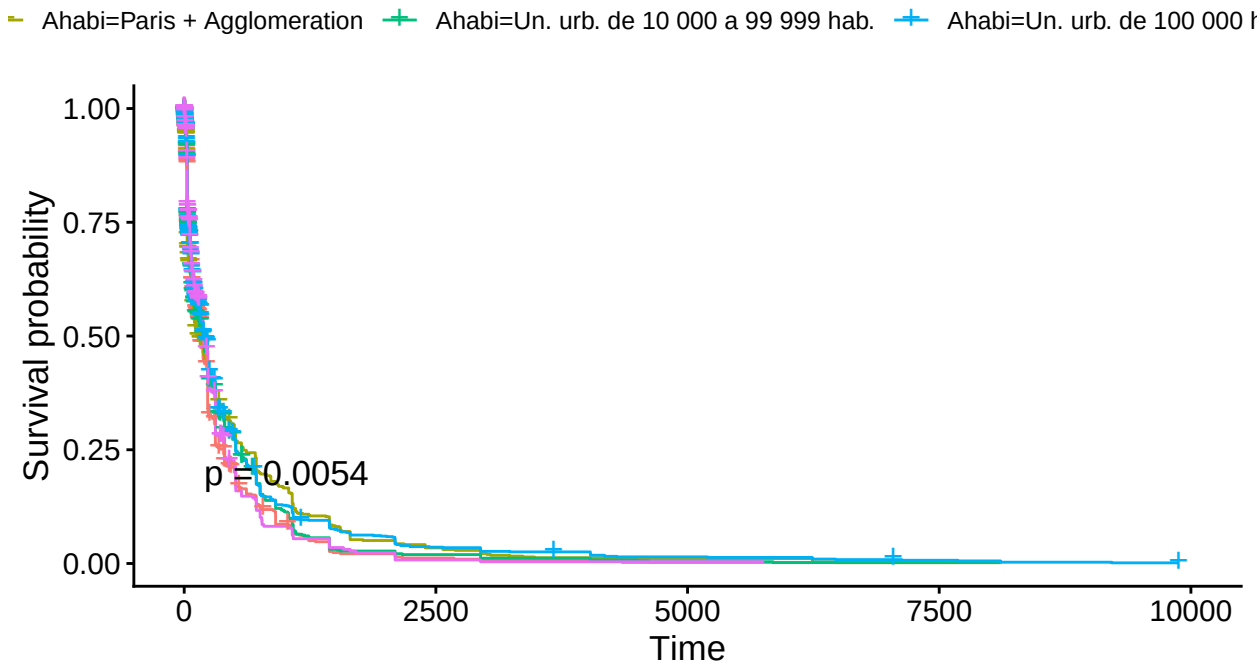

La comparaison des courbes de Kaplan-Meier selon le type d'habitation met en évidence des différences significatives, confirmées par le test du log-rank (p-value = 0,0054). Le type d'habitat influence donc la durée de maintien dans le contrat.

En début de contrat, les courbes sont relativement proches, ce qui suggère des comportements de résiliation similaires à court terme. À moyen terme, des écarts apparaissent : les ménages résidant à Paris et dans son agglomération présentent une probabilité de maintien légèrement supérieure, traduisant une fidélité plus élevée, tandis que certaines zones urbaines de taille intermédiaire affichent un risque de résiliation plus important. Les autres catégories se situent dans une position intermédiaire.

À plus long terme, les écarts tendent à se modifier, avec notamment une meilleure persistance observée pour les ménages résidant dans les grandes unités urbaines (plus de 100 000 habitants).

b)Comparaison selon possession auto (Bauto)

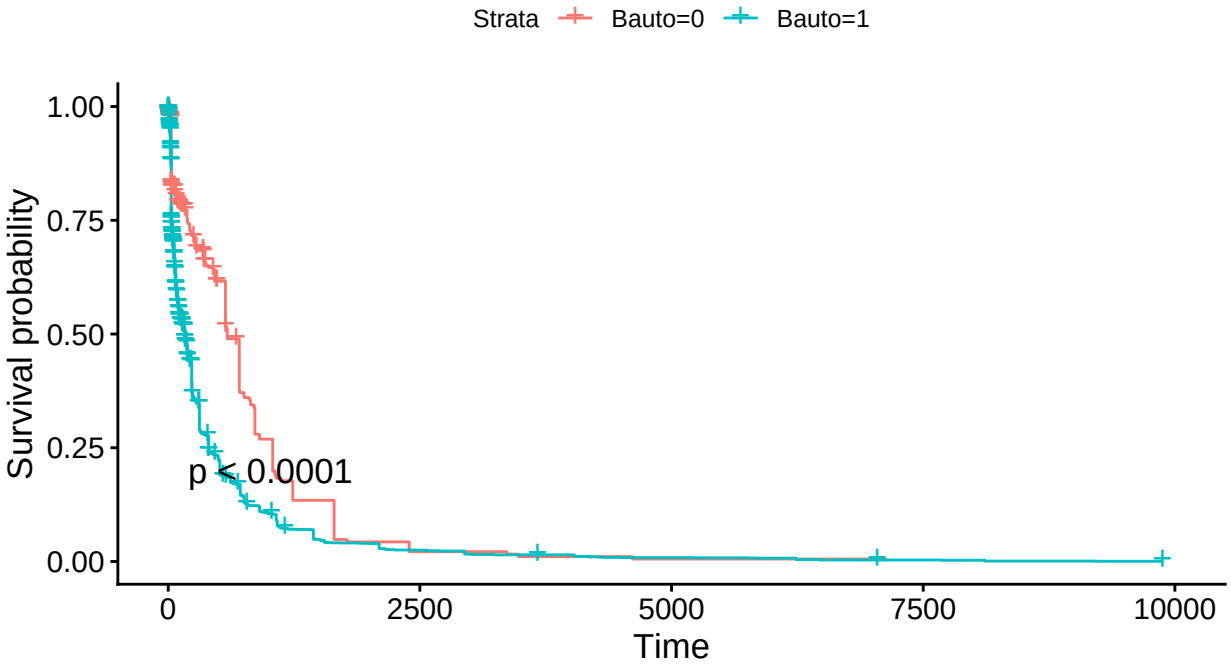

La p-value (0,0001) met en évidence une différence significative selon la possession d'un véhicule.Les ménages ne possédant pas de véhicule présentent une probabilité de maintien dans le contrat plus élevée, traduisant une plus grande fidélité. À l'inverse, les ménages équipés d'au moins un véhicule apparaissent plus enclins à résilier, probablement en raison d'une plus forte exposition à la concurrence. L'écart entre les courbes est marqué en début de contrat, puis tend à se réduire avec le temps.

c)Comparaison selon l'age

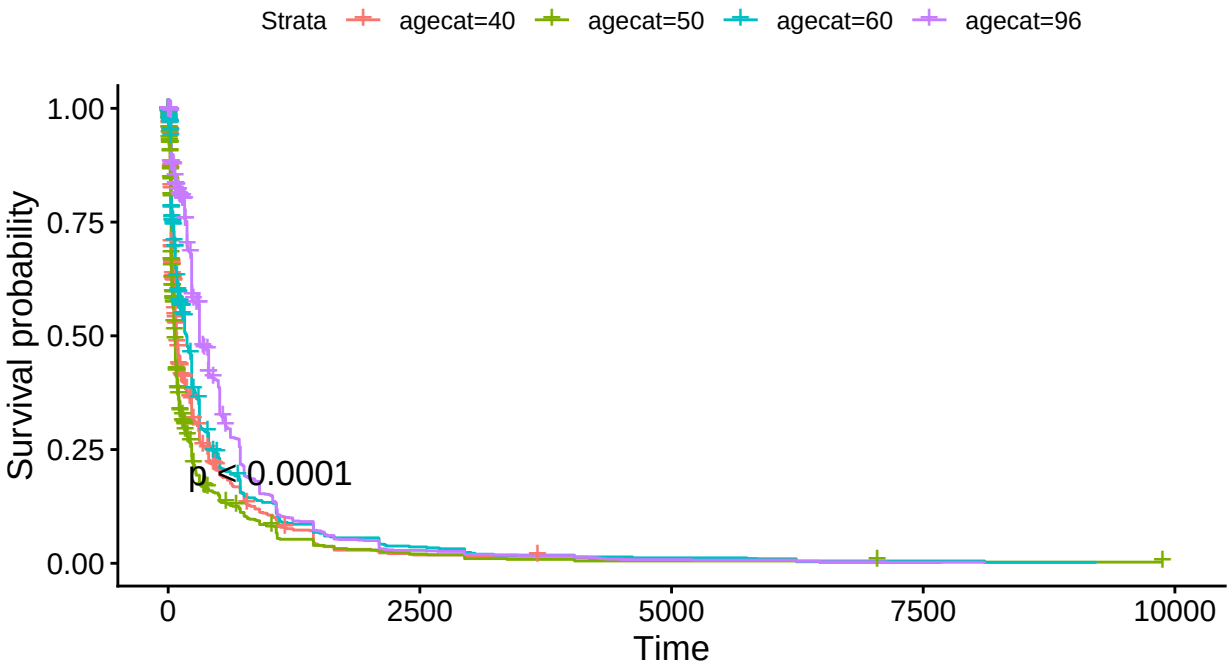

La p-value (0,0001) met en évidence une différence significative entre les classes d'âge en matière de durée de souscription. Les ménages âgés de 61 à 96 ans présentent la probabilité de maintien la plus élevée, traduisant une plus grande fidélité. À l'inverse, les individus âgés de 41 à 50 ans se distinguent par un risque de résiliation plus important, ce qui peut s'expliquer par une période de vie marquée par une plus forte mobilité et des arbitrages plus fréquents entre assureurs. Les autres classes d'âge se situent dans une position intermédiaire. Enfin, les courbes tendent à se rapprocher à long terme, traduisant un effet de sélection des assurés les plus fidèles.

Conclusion

L'analyse de survie met en évidence une hétérogénéité significative de la durée de souscription selon les caractéristiques des assurés. Les estimateurs de Kaplan-Meier montrent que certaines variables, notamment l'âge, le type d'habitat et la possession d'un véhicule, influencent significativement la probabilité de maintien du contrat.

Le modèle de Cox confirme ces résultats en identifiant les facteurs influençant le risque de résiliation. En particulier, les assurés plus âgés ou multi-équipés présentent un risque de résiliation plus faible, traduisant une fidélité plus importante.

Ces résultats sont cohérents avec la théorie actuarielle, où la durée de détention du contrat dépend à la fois du profil de risque et du degré d'engagement de l'assuré.

5.3 Modèle de Cox (modèle explicatif)

```
## Call:
## coxph(formula = Surv_obj ~ pcs + agecat + RUC + Ahabi + Bauto +
##     nbpers, data = dat)
##
##   n= 5352, number of events= 3307
##
##                                            coef  exp(coef)   se(coef)
## pcsArtisans, comm., chefs d'ent.        6.798e-01  1.973e+00  2.637e-01
## pcsAutres pers. sans activite prof.     1.807e-01  1.198e+00  2.722e-01
## pcsCadres et prof. intellectuelles sup. 4.107e-01  1.508e+00  2.515e-01
## pcsEmployes                             6.361e-01  1.889e+00  2.495e-01
## pcsOuvriers                             2.329e-01  1.262e+00  2.483e-01
## pcsProfessions intermediaires           6.645e-01  1.944e+00  2.484e-01
## pcsRetraites                            5.528e-01  1.738e+00  2.552e-01
## agecat50                               -4.286e-02  9.581e-01  5.000e-02
## agecat60                               -4.207e-02  9.588e-01  5.715e-02
## agecat96                               -1.242e-01  8.832e-01  9.035e-02
## RUC                                    -6.107e-05  9.999e-01  5.196e-06
## AhabiParis + Agglomeration              2.914e-02  1.030e+00  6.030e-02
## AhabiUn. urb. de 10 000 a 99 999 hab.   3.566e-02  1.036e+00  5.615e-02
## AhabiUn. urb. de 100 000 hab. et +     -1.957e-01  8.222e-01  5.135e-02
## AhabiUn. urb. de 2 000 a 9 999 hab.     4.284e-02  1.044e+00  6.651e-02
## Bauto                                   1.466e-01  1.158e+00  7.310e-02
## nbpers2                                 9.342e-01  2.545e+00  5.643e-02
## nbpers3                                 1.770e+00  5.874e+00  6.822e-02
## nbpers4                                 2.653e+00  1.419e+01  7.059e-02
##                                             z Pr(>|z|)
## pcsArtisans, comm., chefs d'ent.        2.578 0.009929 **
## pcsAutres pers. sans activite prof.     0.664 0.506662
## pcsCadres et prof. intellectuelles sup. 1.633 0.102478
## pcsEmployes                             2.550 0.010781 *
## pcsOuvriers                             0.938 0.348174
```

```
## pcsProfessions intermediaires            2.675 0.007477 **
## pcsRetraites                             2.166 0.030277 *
## agecat50                                -0.857 0.391423
## agecat60                                -0.736 0.461605
## agecat96                                -1.375 0.169101
## RUC                                    -11.754  < 2e-16 ***
## AhabiParis + Agglomeration               0.483 0.628936
## AhabiUn. urb. de 10 000 a 99 999 hab.    0.635 0.525440
## AhabiUn. urb. de 100 000 hab. et +      -3.812 0.000138 ***
## AhabiUn. urb. de 2 000 a 9 999 hab.      0.644 0.519490
## Bauto                                    2.005 0.044959 *
## nbpers2                                 16.555  < 2e-16 ***
## nbpers3                                 25.951  < 2e-16 ***
## nbpers4                                 37.577  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##                                        exp(coef) exp(-coef) lower .95
## pcsArtisans, comm., chefs d'ent.          1.9735    0.50672    1.1771
## pcsAutres pers. sans activite prof.       1.1981    0.83465    0.7028
## pcsCadres et prof. intellectuelles sup.   1.5079    0.66319    0.9210
## pcsEmployes                               1.8890    0.52937    1.1585
## pcsOuvriers                               1.2623    0.79222    0.7759
## pcsProfessions intermediaires             1.9435    0.51453    1.1943
## pcsRetraites                              1.7382    0.57531    1.0541
## agecat50                                  0.9581    1.04379    0.8686
## agecat60                                  0.9588    1.04297    0.8572
## agecat96                                  0.8832    1.13229    0.7398
## RUC                                       0.9999    1.00006    0.9999
## AhabiParis + Agglomeration                1.0296    0.97128    0.9148
## AhabiUn. urb. de 10 000 a 99 999 hab.     1.0363    0.96497    0.9283
## AhabiUn. urb. de 100 000 hab. et +        0.8222    1.21618    0.7435
## AhabiUn. urb. de 2 000 a 9 999 hab.       1.0438    0.95807    0.9162
## Bauto                                     1.1579    0.86366    1.0033
## nbpers2                                   2.5451    0.39291    2.2786
## nbpers3                                   5.8736    0.17025    5.1384
## nbpers4                                  14.1913    0.07047   12.3576
##                                        upper .95
## pcsArtisans, comm., chefs d'ent.          3.3087
## pcsAutres pers. sans activite prof.       2.0426
## pcsCadres et prof. intellectuelles sup.   2.4685
## pcsEmployes                               3.0802
## pcsOuvriers                               2.0534
## pcsProfessions intermediaires             3.1626
## pcsRetraites                              2.8663
## agecat50                                  1.0567
## agecat60                                  1.0724
## agecat96                                  1.0543
## RUC                                       0.9999
## AhabiParis + Agglomeration                1.1587
## AhabiUn. urb. de 10 000 a 99 999 hab.     1.1569
## AhabiUn. urb. de 100 000 hab. et +        0.9093
## AhabiUn. urb. de 2 000 a 9 999 hab.       1.1891
## Bauto                                     1.3362
```

```
## nbpers2                                    2.8427
## nbpers3                                    6.7139
## nbpers4                                   16.2971
##
## Concordance= 0.77  (se = 0.006 )
## Likelihood ratio test= 2256  on 19 df,   p=<2e-16
## Wald test            = 2451  on 19 df,   p=<2e-16
## Score (logrank) test = 2714  on 19 df,   p=<2e-16
```

Le modèle de Cox met en évidence plusieurs déterminants significatifs de la durée de souscription. Le modèle est globalement très significatif (p-value < 2e-16) et présente une bonne qualité d'ajustement, comme en témoigne une concordance élevée (0,781).

L'âge apparaît comme un facteur clé : le risque de résiliation diminue significativement avec l'âge, traduisant une plus grande fidélité des assurés les plus âgés. De même, les ménages ne possédant pas de véhicule présentent un risque de résiliation plus faible, confirmant les résultats observés avec les courbes de Kaplan-Meier.

Le revenu (RUC) a un effet négatif et significatif sur le risque de résiliation, bien que d'ampleur limitée. À l'inverse, la taille du ménage exerce un effet fortement positif : plus le nombre de personnes dans le ménage est élevé, plus le risque de résiliation augmente.

Enfin, certaines catégories socio-professionnelles présentent un risque de résiliation plus élevé, traduisant une hétérogénéité des comportements selon le profil des assurés. Le type d'habitat joue également un rôle, notamment pour les grandes unités urbaines, où le risque de résiliation apparaît plus faible.

Annexe A : Diagnostics du modèle Hurdle
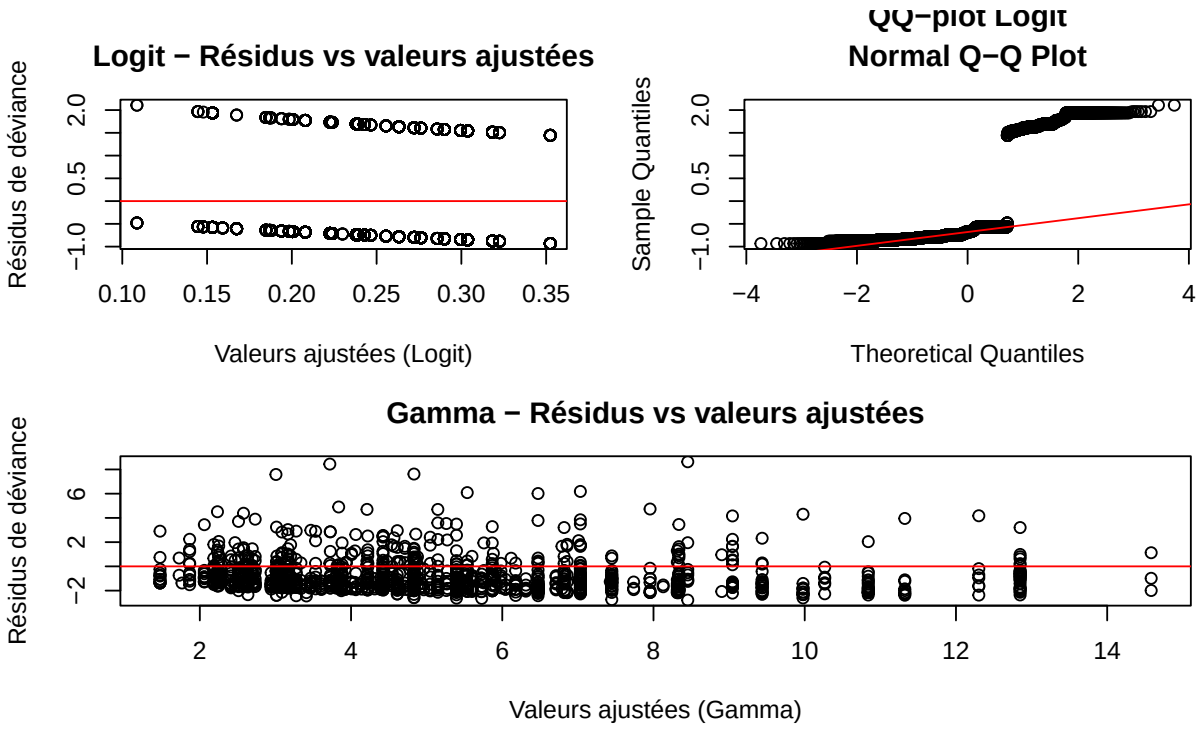
Diagnostics de la fréquence (Logit) et gravité(Gamma)